



吴俊霖

电话: 13160250367 邮箱: junlin-wu@foxmail.com 微信: TallMessiWu
个人网站: tallmessiwu.com GitHub: github.com/TallMessiWu

教育经历

哥伦比亚大学 | 数据科学硕士 | 研究方向: 生成式 AI 与大模型应用

2023年09月 - 2024年12月 | 纽约

加州大学圣地亚哥分校 | 数据科学本科, 辅修经济学 | GPA 3.9/4.0, Cum Laude

2019年09月 - 2023年03月 | 圣地亚哥

工作与实习经历

华为技术有限公司

2025年08月 - 至今 | 上海

AI 工程师 | 计算产品线灵衢集群开发部

- 主导 Flux、Wan 2.2、混元等多模态扩散模型在新一代昇腾芯片上的量化适配与精度调优, 通过算子级 profiling 定位性能瓶颈和精度劣化点, 针对特定算子分析输入输出分布与梯度信息, 迭代调整量化参数和策略, 完成 MindIE SD 生态适配; 推动相关模型达到或超额完成项目性能目标, 充分释放新芯片代际性能收益。
- 基于 Pandas 自研 DiT 块 profiling 自动化分析工具, 支持模糊匹配、跨芯片算子映射和自定义跳过策略, 节省约 **50% 分析时间**, 沉淀为组内规范并覆盖 **5+ 项目**。
- 担任 **Qwen3.5 模型 Owner**, 负责新芯片平台上的 vLLM 端到端适配, 覆盖功能打通、量化、融合算子、PD 分离部署与性能调优; 协调算子、框架、量化团队按期交付, 并沉淀可复用的大模型推理服务化适配方法。
- 为 **SGLang** 构建 MXFP4 / MXFP8 量化推理能力, 覆盖 Diffusion、Dense LLM、MoE LLM 及 W4A4 / W4A8 方案, 同时支持在线量化与基于 msmodelsim 预量化权重的离线推理。

哥伦比亚大学医学院 | Nectow 神经科学实验室

2023年11月 - 2024年12月 | 纽约

数据分析实习生

- 设计端到端神经元活动分析 pipeline, 对活体电生理记录进行去噪、峰电位检测与时间对齐, 通过统计建模量化神经活动与动物进食行为的时序关联, 支持团队识别关键神经肽能神经元对饱腹感的调控机制。
- 使用 Python、Matplotlib、Seaborn 开发可复用的数据处理与可视化流程; 作为合作作者参与数据分析与可视化, 研究论文发表于 **Cell** (2025, DOI: 10.1016/j.cell.2025.01.018)。

项目经历

TD 银行 | 生成式 AI Agent 执行顾问

TallMessiWu/td-llm-streamlit

2024年09月 - 2024年12月 | 纽约

哥伦比亚大学 × TD 银行毕业设计 | 4 人团队核心开发

- 设计并实现面向银行高管决策的 **RAG Agent**, 基于 LangChain、GPT-4、OpenAI Embeddings、Pinecone Serverless 与 Streamlit, 对年度/季度报告和电话会议记录生成带来源引用的回答。
- 自研语义滚动窗口分块: GPT-4 逐页清洗, SentenceTransformer 检测主题边界; 构建 **Top-100 语义召回** → **文件名相似度过滤** → **Top-10 上下文**的多阶段检索, 并保留文件名与页码溯源。
- 实现幻觉验证模块; 以 TruLens LLM-as-Judge 评估回答相关性、忠实度与上下文相关性, 并通过 **LangSmith Tracing** 追踪完整检索和生成链路。

手写 ReAct Agent | GitHub 仓库分析工具

TallMessiWu/react-agent

2026年05月 | 上海

个人项目

- 不依赖 Agent 框架, 从零实现 DeepSeek 驱动的 **ReAct 多轮决策循环**; 以 asyncio、httpx AsyncClient 和 4 个 Function Calling 工具调用 GitHub REST API, 完成仓库探索与结构化报告生成。
- 构建工具级三态熔断器、指数退避与 **30% 随机抖动**、限流降级, 使 Agent 在 API 异常下返回可解释的结构化 fallback, 而非崩溃或编造结果。
- 处理 429 限流、301/302 重定向和 Base64 文件解码等 GitHub API 边界情况, 并提取 DeepSeek reasoning_content 提升 Agent 决策链的可观测性。

核心技能

精通 Python (Pandas / NumPy)、PyTorch、Agent / RAG (**ReAct**、**Function Calling**、**LangChain**、**Pinecone**)、大模型推理与服务化 (**vLLM**、**SGLang**)

熟练 模型量化 (MXFP4 / MXFP8 / INT8)、OpenAI / DeepSeek API、OpenAI Embeddings、TruLens、LangSmith、Streamlit、asyncio / httpx、GitHub REST API

语言 普通话 (母语)、英语 (精通)